

Detekcia stresu z rečového signálu pomocou neurónových sietí

Projektová správa

Martin Šulák, Adrián Zbur, Juraj Mráz, Matej Rábik

3. mája 2026

Obsah

1	Formulácia problému	3
2	Teoretický background	3
2.1	Rečový signál a stres	3
2.2	MFCC príznaky	3
2.3	Log-Mel spektrogram	4
2.4	MLP a CNN	4
2.5	Použité metriky	4
3	Popis datasetu a predspracovanie dát	4
3.1	TESS	4
3.2	CREMA-D	5
3.3	Predspracovanie audia	5
4	Metodológia	5
4.1	Modely	6
4.2	Vyhodnocovanie	6
5	Návrh experimentov	6
5.1	Kontrolovaný experiment – ablation study	6
6	Výsledky	7
6.1	Tabuľka výsledkov	7
6.2	Priebeh tréningovej a validačnej chyby	8
6.3	Confusion matrix a analýza chýb	10
6.4	Výsledky kontrolovaného experimentu – ablation study	11
7	Kritická analýza a diskusia	11
7.1	Interpretácia rozdielu medzi datasetmi	11
7.2	Interpretácia rozdielu medzi modelmi	11
7.3	Diskusia chýb	12
7.4	Kritika metodiky	12
8	Obmedzenia a možnosti ďalšej práce	12
8.1	Obmedzenia	12
8.2	Možnosti ďalšej práce	12
9	Prínos jednotlivých členov tímu	12
10	Zoznam použitej literatúry	13

1 Formulácia problému

Cieľom projektu je navrhnúť, implementovať a experimentálne vyhodnotiť systém na detekciu stresu z rečového signálu pomocou neurónových sietí. Úloha je formulovaná ako binárna klasifikácia. Vstupom je audio nahrávka reči alebo jej odvodená reprezentácia a výstupom je trieda:

- 0 – *no-stress*, teda reč bez prejavu stresu,
- 1 – *stress*, teda reč zaradená do stresovej kategórie.

Formálne ide o hľadanie klasifikačnej funkcie

$$f(x) \rightarrow y, \quad y \in \{0, 1\}, \quad (1)$$

kde x predstavuje rečový signál, MFCC príznaky alebo log-Mel spektrogram a y je cieľový binárny label.

Používané datasety neobsahujú priame fyziologické meranie stresu. Stres je preto aproximovaný cez emočné kategórie. Emócie ako hnev, strach, znechutenie alebo smútok sú mapované do triedy *stress*; neutrálne a pozitívne emócie sú mapované do triedy *no-stress*. Projekt teda nerieši klinickú diagnostiku stresu, ale experimentálnu klasifikáciu stresu odvodeného z emočného prejavu v reči.

Hlavné výskumné otázky projektu sú:

1. Akú úspešnosť dosahujú neurónové siete pri detekcii stresu aproximovaného z emócií?
2. Je pre túto úlohu vhodnejší MLP nad MFCC príznakmi alebo CNN nad log-Mel spektrogramami?
3. Ako sa mení výkonnosť medzi kontrolovaným datasetom TESS a variabilnejším datasetom CREMA-D?
4. Aké typy chýb modely robia a čo tieto chyby znamenajú pre praktické použitie?

2 Teoretický background

2.1 Rečový signál a stres

Rečový signál obsahuje lingvistickú informáciu, ale aj paralingvistické charakteristiky hovoriaceho. Medzi dôležité paralingvistické vlastnosti patria intonácia, tempo reči, energia, hlasitosť, artikulácia a spektrálne zloženie signálu. Psychický stav hovoriaceho môže tieto vlastnosti meniť. Pri strese sa môže meniť základná frekvencia, dynamika hlasu, tempo reči alebo distribúcia energie vo frekvenčnom spektre.

Automatická detekcia stresu z reči je náročná, pretože prejavy stresu nie sú univerzálne. Závisia od hovoriaceho, pohlavia, veku, jazyka, kvality nahrávky, hereckého prejavu a použitého labelovania. Preto treba výsledky interpretovať kriticky a oddeliť vysokú presnosť na kontrolovanom datasete od skutočnej robustnosti v reálnom prostredí.

2.2 MFCC príznaky

MFCC (Mel-Frequency Cepstral Coefficients) sú kompaktné akustické príznaky používané v spracovaní reči. Zachytávajú tvar krátkodobého spektra na Melovej frekvenčnej škále, ktorá približne zodpovedá ľudskému vnímaniu zvuku. Typický výpočet obsahuje rozdelenie signálu na rámce, Fourierovu transformáciu, aplikáciu Mel filtrov, logaritmicкую kompresiu a diskretnú kosínusovú transformáciu.

V projekte sú MFCC príznaky použité ako vstup pre MLP. Ich výhodou je nízka dimensionalita a menšia výpočtová náročnosť. Nevýhodou je, že model dostáva už ručne odvodenú reprezentáciu a nemusí zachytiť všetky lokálne časovo-frekvenčné vzory.

2.3 Log-Mel spektrogram

Log-Mel spektrogram reprezentuje zmenu frekvenčného obsahu signálu v čase. Horizontálna os predstavuje čas, vertikálna os Mel frekvenčné pásma a intenzita vyjadruje energiu signálu. Táto reprezentácia je vhodná pre CNN, pretože ju možno spracovať ako obraz s lokálnymi vzormi.

2.4 MLP a CNN

MLP (Multi-Layer Perceptron) je plne prepojená neurónová sieť. V tomto projekte pracuje s extrahovanými MFCC príznakmi. Model je jednoduchší, rýchlejší a predstavuje dobrý baseline.

CNN (Convolutional Neural Network) pracuje nad log-Mel spektrogramom. Konvolučné vrstvy sa učia lokálne časovo-frekvenčné vzory, ktoré môžu súvisieť so stresom alebo emocionálnym prejavom v reči. Očakávaním bolo, že CNN bude na zložitejších dátach robustnejšia ako MLP.

2.5 Použité metriky

Pretože datasety nie sú dokonale vyvážené, accuracy sama o sebe nestačí. Použili sme preto viacero metrík:

- **Accuracy:** podiel správnych klasifikácií.
- **Precision:** koľko vzoriek označených ako stress bolo skutočne stress.
- **Recall:** koľko skutočných stress vzoriek model zachytil.
- **F1-score:** harmonický priemer precision a recall.
- **ROC-AUC:** separačná schopnosť modelu pri rôznych rozhodovacích prahoch.
- **Confusion matrix:** rozklad chýb na true negative, false positive, false negative a true positive.

3 Popis datasetu a predspracovanie dát

3.1 TESS

TESS (Toronto Emotional Speech Set) obsahuje 2800 rečových nahrávok dvoch herečiek v siedmich emóciách [1]. Dataset nemá priamu anotáciu stresu, preto bolo potrebné emócie namapovať na binárny label. Použité mapovanie je uvedené v tabuľke 1.

Tabuľka 1: Mapovanie emócií v datasete TESS.

Emócie	Trieda	Label
neutral, pleasant surprise	no-stress	0
angry, fear, disgust, sad	stress	1
happy	nepoužité v experimente	–

Po predspracovaní bolo použitých 2400 vzoriek. Z toho 1600 vzoriek patrilo do triedy stress a 800 vzoriek do triedy no-stress. Testovacia množina obsahovala 480 vzoriek.

3.2 CREMA-D

CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset) je multimodálny emočný dataset obsahujúci nahrávky od 91 hercov [2]. V projekte bola použitá audio časť. Názvy súborov obsahujú informáciu o hercovi, vete, emócií a intenzite, napríklad 1001_DFA_ANG_XX.wav.

Tabuľka 2: Mapovanie emócií v datasete CREMA-D.

Kód emócie	Význam	Label
HAP, NEU	happy, neutral	0 (no-stress)
ANG, DIS, FEA, SAD	anger, disgust, fear, sadness	1 (stress)

Po predspracovaní bolo použitých 7441 vzoriek. Trieda stress obsahovala 5083 vzoriek a trieda no-stress obsahovala 2358 vzoriek. Testovacia množina obsahovala 1489 vzoriek.

3.3 Predspracovanie audia

Predspracovanie bolo zjednotené pre oba datasety:

- audio bolo načítané zo súborov WAV,
- signál bol resamplovaný na 16 kHz,
- dĺžka signálu bola zarovnaná na fixný interval 3 sekundy pomocou orezania alebo doplnenia,
- pre MLP boli extrahované MFCC príznaky,
- pre CNN boli vypočítané log-Mel spektrogramy,
- spracované reprezentácie boli uložené ako .npy súbory.

Tabuľka 3: Súhrn datasetov po predspracovaní.

Dataset	Použité vzorky	No-stress	Stress	Testovacie vzorky
TESS	2400	800	1600	480
CREMA-D	7441	2358	5083	1489

4 Metodológia

Experimenty boli realizované v jazyku Python pomocou knižnice PyTorch. Finálny beh bol spustený na GPU s podporou CUDA príkazom:

```
python run.py --dataset all --model all --deterministic --device cuda
```

Použitý bol deterministický režim, aby boli výsledky reprodukovateľnejšie. Pre každú kombináciu datasetu a modelu sa vytvorili dátové množiny train, validation a test. Model sa učil na trénovacej množine, validačná množina slúžila na sledovanie priebehu tréningu a testovacia množina bola použitá až na finálne vyhodnotenie.

4.1 Modely

Pre každý dataset boli testované dva modely:

- **MLP**: vstupom boli MFCC príznaky, model vracal jeden logit pre binárnu klasifikáciu.
- **CNN**: vstupom bol log-Mel spektrogram, model vracal jeden logit pre binárnu klasifikáciu.

Ako stratová funkcia bola použitá `BCEWithLogitsLoss`, pretože ide o binárnu klasifikáciu s jedným výstupným logitom. Po aplikovaní sigmoid funkcie sa z logitu získa pravdepodobnosť triedy stress.

4.2 Vyhodnocovanie

Pre každý experiment boli uložené:

- tréningové a validačné krivky loss a accuracy,
- confusion matrix,
- súhrnné metriky accuracy, precision, recall, F1-score a ROC-AUC,
- spoločné ROC krivky a porovnávací graf metrík.

5 Návrh experimentov

Experimenty boli navrhnuté tak, aby bolo možné porovnať vplyv datasetu aj vplyv modelovej architektúry. Základné experimenty sú uvedené v tabuľke 4.

Tabuľka 4: Základné experimenty.

ID	Dataset	Vstupná reprezentácia	Model
E1	TESS	MFCC príznaky	MLP
E2	TESS	log-Mel spektrogram	CNN
E3	CREMA-D	MFCC príznaky	MLP
E4	CREMA-D	log-Mel spektrogram	CNN

5.1 Kontrolovaný experiment – ablation study

Ako kontrolovaný experiment bola zvolená ablation study na datasete CREMA-D. Referenčný variant je CNN nad log-Mel spektrogramom. Ablovaný variant odstraňuje konvolučnú časovo-frekvenčnú vetvu a nahrádza ju jednoduchším MLP modelom nad MFCC príznakmi.

Kontrolované zostali:

- rovnaký dataset CREMA-D,
- rovnaké mapovanie emócií na stress/no-stress,
- rovnaké rozdelenie train/validation/test,
- rovnaký počet tried a rovnaké metriky,
- rovnaký finálny vyhodnocovací protokol na testovacej množine.

Mení sa iba modelová vetva a vstupná reprezentácia: *MFCC + MLP* oproti *log-Mel spektrogram + CNN*. Cieľom bolo overiť, či je konvolučné spracovanie spektrogramu prínosné oproti jednoduchšiemu príznakovému modelu.

6 Výsledky


6.1 Tabuľka výsledkov

Tabuľka 5 uvádza finálne testovacie metriky všetkých štyroch experimentov.


Tabuľka 5: Súhrnné výsledky na testovacej množine.

Dataset	Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
TESS	MLP	0.9917	0.9877	1.0000	0.9938	0.9994
TESS	CNN	0.9979	1.0000	0.9969	0.9984	1.0000
CREMA-D	MLP	0.7045	0.7187	0.9322	0.8116	0.7166
CREMA-D	CNN	0.7804	0.7842	0.9361	0.8534	0.8386

Na TESS dosiahli oba modely takmer perfektné výsledky. Na CREMA-D boli výsledky nižšie, ale informatívnejšie z pohľadu generalizácie. CNN dosiahla na CREMA-D lepšie hodnoty accuracy, F1-score aj ROC-AUC ako MLP.




Obr. 1: Porovnanie hlavných metrík pre jednotlivé experimenty.




Obr. 2: ROC krivky pre realizované experimenty.

6.2 Pribeh tréningovej a validačnej chyby


Tréningové krivky zobrazujú priebeh loss a accuracy na trénovacej a validačnej množine. Slúžia na kontrolu stability učenia a na identifikáciu možného overfittingu.




Obr. 3: Pribeh tréningu a validácie pre TESS + MLP.



Obr. 4: Priebeh tréningu a validácie pre TESS + CNN.




Obr. 5: Priebeh tréningu a validácie pre CREMA-D + MLP.




Obr. 6: Priebeh tréningu a validácie pre CREMA-D + CNN.

Pri TESS krivky ukazujú rýchlu konvergenciu a vysokú validačnú presnosť. Pri CREMA-D je tréning náročnejší; validačné metriky sú nižšie a medzi modelmi je jasnejší rozdiel. CNN dosahuje stabilnejší a vyšší validačnú výkonnosť než MLP.

6.3 Confusion matrix a analýza chýb



Obr. 7: Confusion matrix pre dataset TESS.



Obr. 8: Confusion matrix pre dataset CREMA-D.

Tabuľka 6: Rozklad chýb z confusion matrices. Riadky matice sú skutočné triedy, stĺpce predikované triedy.

Dataset	Model	TN	FP	FN	TP	FPR	FNR
TESS	MLP	156	4	0	320	0.0250	0.0000
TESS	CNN	160	0	1	319	0.0000	0.0031
CREMA-D	MLP	101	371	69	948	0.7860	0.0678
CREMA-D	CNN	210	262	65	952	0.5551	0.0639

Na TESS boli chyby minimálne. MLP nesprávne označil 4 no-stress vzorky ako stress, ale nezmeškal žiadnu stress vzorku. CNN klasifikovala všetky no-stress vzorky správne a urobila iba jednu false negative chybu.

Na CREMA-D je analýza chýb dôležitejšia. MLP vytvoril 371 false positive chýb, teda veľmi často označoval no-stress vzorky ako stress. CNN tento problém zmenšila: počet false positive chýb klesol z 371 na 262 a počet true negative predikcií stúpol zo 101 na 210. False negative chyby zostali podobné (69 pri MLP, 65 pri CNN). To znamená, že hlavný prínos CNN je lepšie rozpoznávanie triedy no-stress bez straty schopnosti zachytiť stress vzorky.

6.4 Výsledky kontrolovaného experimentu – ablation study

Tabuľka 7 porovnáva referenčný model CREMA-D + CNN s ablovaným variantom CREMA-D + MLP. Keďže dataset, mapovanie tried a vyhodnocovanie zostali rovnaké, rozdiely interpretujeme ako prínos konvolučného spracovania log-Mel spektrogramu oproti príznakovému MLP baseline.

Tabuľka 7: Ablation study na datasete CREMA-D.

Variant	Accuracy	Precision	Recall	F1-score	ROC-AUC
Ablovaný variant: MFCC + MLP	0.7045	0.7187	0.9322	0.8116	0.7166
Referenčný variant: log-Mel + CNN	0.7804	0.7842	0.9361	0.8534	0.8386
Rozdiel CNN - MLP	+0.0759	+0.0655	+0.0039	+0.0418	+0.1220

Ablation study ukazuje, že CNN vetva priniesla na CREMA-D zlepšenie vo všetkých hlavných metrikách. Najvýraznejší rozdiel je pri ROC-AUC, ktoré vzrástlo z 0.7166 na 0.8386. To znamená, že CNN nielen zlepšila tvrdé rozhodnutia po prahovaní, ale aj lepšie separovala triedy na úrovni pravdepodobnostných skóre.

7 Kritická analýza a diskusia

7.1 Interpretácia rozdielu medzi datasetmi

Najvýraznejší rozdiel sa ukázal medzi datasetmi. TESS dosahuje takmer perfektné výsledky, no ide o kontrolovaný dataset s dvoma herečkami a veľmi čistými nahrávkami. Model sa preto pravdepodobne učí dobre separovateľné emočné prejavy, nie univerzálny stres.

CREMA-D je väčší a variabilnejší. Obsahuje viac hercov a viac akustickej variability. Preto sú výsledky nižšie, ale z hľadiska hodnotenia modelov realistickejšie. Skutočnosť, že modely majú na CREMA-D problém s triedou no-stress, ukazuje, že detekcia stresu odvodeného z emócií nie je triviálna.

7.2 Interpretácia rozdielu medzi modelmi

Na TESS je rozdiel medzi MLP a CNN malý, pretože úloha je pre zvolené mapovanie veľmi dobre separovateľná. Na CREMA-D je rozdiel podstatný. CNN dosahuje lepší F1-score aj ROC-AUC, čo podporuje predpoklad, že log-Mel spektrogram a konvolučné vrstvy lepšie zachytávajú časovo-frekvenčné vzory než agregované MFCC príznaky.

7.3 Diskusia chýb

Pri praktickej detekcii stresu majú false positive a false negative chyby rozdielny význam. False positive znamená, že systém označí nestresovú reč ako stresovú; to vedie k falošným upozorneniam. False negative znamená, že systém nezachytí skutočný stres. V mnohých aplikáciách je false negative kritickejšia, ale vysoký počet false positives znižuje použiteľnosť systému.

CREMA-D modely dosahujú vysoký recall, teda zachytávajú väčšinu stress vzoriek. Ich hlavným problémom je nižšia schopnosť správne identifikovať no-stress vzorky. CNN je v tomto smere lepšia ako MLP, no stále má false positive rate 0.5551, čo je pre praktické nasadenie vysoké.

7.4 Kritika metodiky

Najväčší metodický limit je mapovanie emócií na stres. Hnev alebo strach nemusia vždy znamenať stres a neutrálny prejav nemusí vždy znamenať absenciu stresu. Výsledky preto treba interpretovať ako klasifikáciu emočného proxy labelu, nie ako priamu detekciu psychologického stresu.

8 Obmedzenia a možnosti ďalšej práce

8.1 Obmedzenia

- Stres nie je meraný priamo, ale odvodený z emočných kategórií.
- Triedy sú nevyvážené, najmä pri CREMA-D, kde stress vzorky tvoria väčšinu dát.
- TESS obsahuje iba dve herečky, preto neposkytuje silný test generalizácie na nových hovoriacich.
- CREMA-D je herecký emočný dataset; prejavy nemusia zodpovedať prirodzenému stresu.
- Modely pracujú s fixnou dĺžkou segmentu 3 sekundy, čo môže odstrániť časť kontextu.
- Na CREMA-D ostáva vysoký počet false positive chýb.

8.2 Možnosti ďalšej práce

- Použiť speaker-independent split, aby sa overila generalizácia na nevidených hovoriacich.
- Použiť weighted loss alebo focal loss na zmiernenie triednej nevyváženosti.
- Vyhodnotiť výsledky osobitne podľa emócií, aby bolo jasné, ktoré emócie spôsobujú najviac chýb.
- Doplniť rozsiahlejšie ablation study pre augmentácie, počet Mel filtrov, dropout, weight decay a dĺžku audio segmentu.
- Otestovať modernejšie audio reprezentácie, napríklad wav2vec2 alebo HuBERT embeddingy.
- Použiť dataset s priamymi stresovými anotáciami alebo fyziologickými meraniami.

9 Prínos jednotlivých členov tímu

Tabuľka 8 uvádza rozdelenie práce v tíme. V prípade potreby je možné jednotlivé formulácie upraviť podľa finálnej dohody členov tímu.

Tabuľka 8: Prínos členov tímu.

Člen tímu	Prínos
Adrián Zbur	Návrh a správa projektovej štruktúry, práca s repozitárom, koordinácia podkladov, pomoc pri výstupoch projektu.
Juraj Mráz	Integrácia nového datasetu CREMA-D, úprava projektu po vyradení WS3D, kontrola dátovej časti.
Matej Rábik	Testovanie kódu a datasetov, kontrola experimentálneho pipeline, overenie behov a konzistencie výsledkov.
Martin Šulák	Spustenie finálnych experimentov, spracovanie metrík a grafov, interpretácia výsledkov, vypracovanie reportu a prezentačných podkladov.

10 Zoznam použitej literatúry

Literatúra

- [1] University of Toronto. *Toronto Emotional Speech Set (TESS)*. Dostupné online: <https://borealisdata.ca/dataset.xhtml?persistentId=doi:10.5683/SP2/E8H2MF>
- [2] Cao, H., Cooper, D. G., Keutmann, M. K., Gur, R. C., Nenkova, A., Verma, R. *CREMA-D: Crowd-sourced Emotional Multimodal Actors Dataset*. IEEE Transactions on Affective Computing, 2014. Dostupné online: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4313618/>
- [3] Paszke, A. et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. NeurIPS, 2019. Dokumentácia: <https://pytorch.org/>
- [4] McFee, B. et al. *librosa: Audio and Music Signal Analysis in Python*. Proceedings of the 14th Python in Science Conference, 2015. Dokumentácia: <https://librosa.org/>
- [5] Davis, S., Mermelstein, P. *Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences*. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1980.
- [6] Park, D. S. et al. *SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition*. Interspeech, 2019.