

1. Formulácia problému

Cieľom tohto projektu je navrhnúť a experimentálne vyhodnotiť modely neurónových sietí pre úlohu detekcie stresu z rečového signálu.

Detekcia stresu z hlasu patrí do oblasti spracovania reči a afektívneho počítania, kde sa analyzujú paralingvistické vlastnosti reči, ako sú intonácia, energia, tempo a spektrálne charakteristiky, s cieľom odhadnúť psychický stav hovoriaceho.

V tomto projekte pristupujeme k problému dvoma rôznymi spôsobmi:

- **(1) Priama detekcia stresu**
Pomocou datasetu WESAD, ktorý obsahuje explicitné anotácie stresu (napr. *stress*, *baseline*, *amusement*), formulujeme úlohu ako klasifikačný problém, kde:
 - vstupom je rečový signál,
 - výstupom je úroveň stresu.
- **(2) Nepriama detekcia stresu pomocou emócií**
Pomocou datasetu TESS, ktorý obsahuje emocionálne kategórie (napr. *anger*, *fear*, *happy*, *neutral*), aproximujeme stres prostredníctvom vybraných emócií. Konkrétne:
 - stresové stavy sú reprezentované emóciami ako *anger* a *fear*,
 - nestresové stavy sú reprezentované emóciami ako *neutral* alebo *happy*.

Na základe toho formulujeme druhú úlohu ako klasifikáciu stresu odvodeného z emocionálnych kategórií.

Hlavným cieľom projektu je porovnať tieto dva prístupy:

- detekciu stresu z dát s explicitnými anotáciami,
- detekciu stresu aproximovaného z emocionálnych dát,

a analyzovať rozdiely v ich výkonnosti, robustnosti a schopnosti generalizácie.

Na riešenie úlohy budú použité rôzne modelové prístupy, vrátane:

- klasických metód strojového učenia využívajúcich extrahované príznaky (napr. MFCC),
- modelov hlbokého učenia pracujúcich so spektrogramami.

Cieľom nie je len dosiahnuť vysokú presnosť klasifikácie, ale najmä porozumieť správaniu modelov, identifikovať ich obmedzenia a vysvetliť rozdiely medzi jednotlivými prístupmi.

2. Teoretický background

Detekcia stresu z rečového signálu patrí do oblasti spracovania reči (*speech processing*) a afektívneho počítania (*affective computing*), ktoré sa zameriava na automatickú analýzu emocionálnych a psychologických stavov človeka na základe signálov, ako je reč, obraz alebo fyziologické dáta.

2.1 Rečový signál a jeho vlastnosti

Rečový signál je časovo premenlivý akustický signál, ktorý nesie nielen lingvistickú informáciu (obsah slov), ale aj paralingvistické informácie, ako sú emócie, stres či nálada hovoriaceho.

Stres ovplyvňuje viacero charakteristík reči, napríklad:

- **pitch (základná frekvencia)** – pri strese sa často zvyšuje,
- **energia signálu** – môže byť vyššia alebo kolísavá,
- **tempo reči** – môže sa zrýchliť alebo spomaliť,
- **spektrálne vlastnosti** – mení sa rozloženie energie vo frekvenčnom spektre.

Tieto zmeny umožňujú modelom strojového učenia identifikovať stresové stavy priamo zo signálu.

2.2 Extrakcia príznakov z reči

Surový audio signál nie je priamo vhodný ako vstup pre väčšinu modelov, preto sa transformuje na reprezentácie, ktoré zachytávajú jeho relevantné vlastnosti.

MFCC (Mel-Frequency Cepstral Coefficients)

MFCC patria medzi najčastejšie používané príznaky v spracovaní reči. Reprezentujú krátkodobé spektrálne vlastnosti signálu na základe Melovej frekvenčnej škály, ktorá aproximuje ľudské vnímanie zvuku.

Výpočet MFCC zahŕňa:

- prevod signálu do frekvenčnej oblasti (Fourierova transformácia),
- aplikáciu Melových filtrov,
- logaritmicкую kompresiu,
- diskretnú kosínusovú transformáciu.

MFCC efektívne zachytávajú tvar spektra a sú vhodné pre klasické modely strojového učenia.

Spektrogram a Mel-spektrogram

Spektrogram je vizuálna reprezentácia signálu, ktorá zobrazuje, ako sa frekvenčné spektrum mení v čase.

- os x: čas
- os y: frekvencia
- intenzita: energia signálu

Mel-spektrogram je modifikácia, ktorá používa Melovu škálu frekvencií.

Tieto reprezentácie sú vhodné ako vstup pre konvolučné neurónové siete (CNN), pretože majú charakter obrazu.

2.3 Prístupy k detekcii stresu

V tomto projekte sa využívajú dva základné prístupy:

Priama detekcia stresu

Model je trénovaný na dátach, ktoré obsahujú explicitné anotácie stresu (napr. WESAD). Výhodou je, že model sa učí priamo cieľovú veličinu bez potreby aproximácie.

Nepriama detekcia pomocou emócií

Keď dataset neobsahuje priamo stres, využíva sa aproximácia pomocou emocionálnych kategórií. Napríklad emócie ako hnev alebo strach môžu reprezentovať stresové stavy.

Tento prístup je menej presný, ale umožňuje využívať širšie dostupné datasety.

2.4 Modely strojového učenia

Klasické metódy

Modely ako Support Vector Machines (SVM) alebo Random Forest pracujú s vopred extrahovanými príznakmi (napr. MFCC). Sú menej náročné na dáta a často poskytujú dobrý baseline.

Hlboké neurónové siete

Konvolučné neurónové siete (CNN)

CNN sú vhodné pre spracovanie obrazových dát, ako sú spektrogramy. Dokážu automaticky extrahovať lokálne vzory vo frekvenčno-časovej reprezentácii signálu.

Výhodou je schopnosť učiť sa komplexné nelineárne vzťahy bez potreby ručného výberu príznakov.

2.5 Výzvy pri detekcii stresu

Detekcia stresu z reči je náročná úloha z viacerých dôvodov:

- variabilita medzi hovoriacimi (hlas, pohlavie, jazyk),
- rozdiel medzi hranými a reálnymi emóciami,
- šum a kvalita nahrávok,
- nejednoznačnosť medzi emóciami (napr. stres vs. hnev).

Tieto faktory ovplyvňujú generalizáciu modelov a musia byť zohľadnené pri interpretácii výsledkov.